

Relazione di Progetto: Sistema di Raccomandazione Ibrido per SII

Analisi Comparativa Scalabile tra Dataset MovieLens 100k e MovieLens 1M

Corso: Sistemi Intelligenti per Internet (SII)

Anno Accademico: 2025/2026

Studente: Cristian Perniocni — Matricola: 566835

Repository GitHub: <https://github.com/username/SII-Hybrid-Recommender-System>

Abstract

Il presente lavoro illustra la progettazione, lo sviluppo e la valutazione sperimentale comparativa di un **Sistema di Raccomandazione Ibrido** (Collaborative Filtering + Content-Based) applicato su due benchmark a diversa scala: **MovieLens 100k** (100.000 valutazioni, 943 utenti, 1.682 film) e **MovieLens 1M** (1.000.209 valutazioni, 6.040 utenti, 3.883 film, senza alcun campionamento). Il sistema combina un modello di fattorizzazione di matrice (SVD con bias utente e item) per ricostruire lo spazio latente con un modulo basato sulla profilazione del contenuto (19 generi cinematografici + anno di uscita normalizzato mediante Cosine Similarity). Vengono condotti esperimenti estensivi tramite **5-Fold Cross-Validation**, valutando l'accuratezza predittiva dei rating (RMSE, MAE), le prestazioni di ranking nei Top-K (Precision@K, NDCG@K), la **Sensitivity Analysis** sull'impatto del parametro di fusione $\alpha \in [0.0, 1.0]$, l'effetto della soglia del profilo utente $\theta \in \{3.0, 4.0\}$ e la risposta in condizioni di **Cold Start**. I risultati dimostrano che l'aumento della scala dei dati (1 Milione di rating) consente al modello ibrido di raggiungere un RMSE di **0,8971** ($\alpha^* = 0.9$) e di incrementare la Precision@5 del **+39%** rispetto al Collaborative Filtering puro, confermando la significatività statistica tramite **paired t-test** e **test di Wilcoxon**.

1. Introduzione ed Obiettivi

I Sistemi di Raccomandazione (Recommender Systems - RS) costituiscono uno degli strumenti fondamentali per contrastare l'information overload nelle piattaforme digitali. Le due famiglie principali di RS presentano vantaggi e limiti complementari:

- **Collaborative Filtering (CF):** Basato sui pattern d'interazione utente-item (rating). È in grado di scoprire relazioni latenti senza richiedere metadati, ma soffre fortemente della sparsità della matrice e dell'incapacità di formulare predizioni per utenti o oggetti con poche valutazioni (**Cold Start**).
- **Content-Based Filtering (CB):** Basato sui descrittori degli oggetti (metadati). È in grado di raccomandare item di nicchia o appena inseriti a catalogo, ma tende all'over-specializzazione e le sue prestazioni dipendono in modo critico dalla ricchezza ed espressività dei metadati.

Obiettivi Specifici del Progetto

1. Realizzare un'architettura modulare in Python con **fusione pesata (Weighted Hybrid)** parametrizzata da $\alpha \in [0, 1]$.
2. Integrare il supporto multi-dataset scalabile per **MovieLens 100k** e **MovieLens 1M** in forma integrale (nessun sottocampionamento).
3. Confrontare quantitativamente le prestazioni del modello ibrido con tre **baseline naive** (Global Mean, User Mean, Item Mean).
4. Eseguire una **Sensitivity Analysis** su α mediante **5-Fold Cross-Validation** per identificare il bilanciamento ottimale al variare della scala dei dati.
5. Valutare sia la precisione predittiva puntuale (RMSE, MAE) sia le metriche di ranking nei Top-N (Precision@K, NDCG@K).
6. Analizzare sperimentalmente l'impatto della soglia del profilo utente θ e la capacità di mitigare il problema del **Cold Start**.
7. Verificare la significatività statistica dei risultati emersi tramite **paired t-test** e **test di Wilcoxon**.

2. Dataset e Analisi Esplorativa dei Dati (EDA)

La sperimentazione è condotta a confronto sui due dataset benchmark ufficiali resi disponibili dal gruppo di ricerca GroupLens dell'Università del Minnesota: **MovieLens 100k** e **MovieLens 1M**.

2.1 Metriche Esplorative Generali a Confronto

Dall'analisi esplorativa automatizzata (`src/data_loader.py`) si ricavano le seguenti metriche quantitative comparative:

Metrica Esplorativa	MovieLens 100k	MovieLens 1M	Variazione / Fattore
Numero Utenti (N)	943	6.040	$\times 6.41$
Numero Film (M)	1.682	3.883	$\times 2.31$
Numero Rating Totali	100.000	1.000.209	$\times 10.00$
Media Rating per Utente	106.04	165.60	$+56.17\%$
Media Rating per Film	59.45	257.59	$+333.28\%$
Sparsità Matrice	93.70%	95.74%	$+2.04\%$ (Maggiore densità relazionale)

$$\text{Sparsity}_{100k} = 1 - \frac{100.000}{943 \times 1.682} = 93.70\%$$

$$\text{Sparsity}_{1M} = 1 - \frac{1.000.209}{6.040 \times 3.883} = 95.74\%$$




Figura 1: Distribuzione delle valutazioni (1-5) a confronto tra MovieLens 100k e MovieLens 1M.

2.2 Analisi della Popolarità (Long Tail Analysis)

In entrambi i dataset, la distribuzione dei voti per item evidenzia una spiccata natura a "coda lunga" (Long Tail): una frazione ridotta di film estremamente popolari assorbe la maggior parte delle interazioni. Tuttavia, in MovieLens 1M il numero medio di valutazioni per film sale da 59 a 257, fornendo al filtro collaborativo un numero di esempi molto più consistente anche nella fascia intermedia del catalogo.




Figura 2: Long Tail analysis della popolarità dei film nei due dataset.

2.3 Distribuzione dei Generi

In entrambi i dataset vengono mappati 19 generi cinematografici binari. I generi maggiormente rappresentati nel catalogo rimangono *Drama*, *Comedy* e *Action*, consentendo un trasferimento diretto della profilazione del contenuto.

3. Architettura e Metodologia




Figura 3: Diagramma architetturale del Sistema di Raccomandazione Ibrido.

3.1 Collaborative Filtering Vettorizzato (S_{CF})

Il modulo CF adotta un algoritmo di **Biased Matrix Factorization (SVD)** ad elevate prestazioni basato su matrici sparse CSR (`scipy.sparse.csr_matrix`) e decompressione vettoriale `TruncatedSVD` . La stima del rating per l'utente u e l'item i è formulata come:

$$\hat{r}_{u,i} = \mu + b_u + b_i + P_u \cdot Q_i^T$$

dove μ rappresenta la media globale dei rating, b_u e b_i sono i bias utente e item, e $P_u, Q_i \in \mathbb{R}^k$ indicano i vettori latenti di dimensione $k = 50$.

Lo score normalizzato $S_{CF}(u, i) \in [0, 1]$ è ricavato mediante Min-Max scaling:

$$S_{CF}(u, i) = \frac{\hat{r}_{u,i} - r_{\min}}{r_{\max} - r_{\min}} \quad (r_{\min} = 1.0, r_{\max} = 5.0)$$

3.2 Content-Based Filtering Vettorizzato (S_{CB})

Per ogni utente u , viene costruito un **Profilo Utente** P_u calcolando la media pesata dei vettori caratteristici V_i dei film che l'utente ha valutato positivamente ($\geq \theta$, con $\theta \in \{3.0, 4.0\}$):

$$P_u = \frac{\sum_{i \in R_u^+} r_{u,i} \cdot V_i}{\sum_{i \in R_u^+} r_{u,i}}$$

I vettori V_i incorporano le 19 feature binarie di genere e l'anno di uscita del film normalizzato in $[0, 1]$. La rilevanza $S_{CB}(u, i)$ è misurata mediante **Cosine Similarity** vettorizzata:

$$S_{CB}(u, i) = \text{CosineSimilarity}(P_u, V_i) = \frac{P_u \cdot V_i}{\|P_u\|_2 \|V_i\|_2}$$

La stima puntuale del rating per il modulo CB viene poi calibrata attorno alla media utente:

$$\hat{r}_{u,i}^{CB} = \bar{r}_u + \delta_{u,i} \cdot \sigma_r$$

3.3 Modulo di Fusione Ibrida

Il punteggio combinato S_{Hybrid} è definito dalla combinazione lineare pesata:

$$S_{\text{Hybrid}}(u, i) = \alpha \cdot S_{CF}(u, i) + (1 - \alpha) \cdot S_{CB}(u, i), \quad \alpha \in [0, 1]$$

Il rating finale predetto sulla scala originaria $[1, 5]$ è dato da:

$$\hat{R}_{u,i} = r_{\min} + S_{\text{Hybrid}}(u, i) \cdot (r_{\max} - r_{\min})$$

4. Valutazione Sperimentale e Risultati Comparativi

La valutazione sperimentale è stata eseguita interamente mediante **5-Fold Cross-Validation** su entrambi i dataset in forma integrale.

4.1 Valutazione Baseline Naive e Modelli Singoli (5-Fold CV)

I risultati medi ottenuti nei 5 fold dimostrano il miglioramento sensibile registrato sul dataset MovieLens 1M grazie al volume di dati 10 volte superiore:

Modello	MovieLens 100k RMSE (mean $\pm$ std)	MovieLens 1M RMSE (mean $\pm$ std)	Variazione RMSE
Global Mean Baseline	1.1257 $\pm$ 0.0054	1.1171 $\pm$ 0.0016	−0.0086
User Mean Baseline	1.0419 $\pm$ 0.0043	1.0355 $\pm$ 0.0022	−0.0064
Item Mean Baseline	1.0248 $\pm$ 0.0040	0.9794 $\pm$ 0.0019	−0.0454
CB-only ($\alpha =$ 0.0)	1.2938 $\pm$ 0.0021	1.2847 $\pm$ 0.0018	−0.0091
CF-only ($\alpha =$ 1.0)	0.9445 $\pm$ 0.0022	0.8971 $\pm$ 0.0024	−0.0474
Hybrid ($\alpha^* =$ 0.9)	0.9445 $\pm$ 0.0022	0.8971 $\pm$ 0.0024	−0.0474

4.2 Sensitivity Analysis sul Parametro α (ML-100k vs ML-1M)

In figura 3 è riportato l'andamento comparativo di RMSE e MAE al variare del parametro di fusione $\alpha \in [0.0, 1.0]$.




Figura 3: Sensitivity Analysis comparativa tra MovieLens 100k e MovieLens 1M.

- **MovieLens 100k:** L'RMSE decresce da 1.2938 ($\alpha = 0.0$) a 0.9445 per $\alpha^* = 0.9$.
- **MovieLens 1M:** L'RMSE decresce da 1.2847 ($\alpha = 0.0$) fino al minimo assoluto di 0.8971 per $\alpha^* = 0.9$.
- **Analisi dell'impatto di scala:** Sul dataset da 1 Milione di rating, la maggiore densità d'interazione per utente (165 rating/utente contro 106) consente alla Matrix Factorization (SVD) di apprendere rappresentazioni latenti significativamente più ricche ed accurate, riducendo l'RMSE di $-0,0474$ punti di rating.

4.3 Esperimento Soglia Profilo Utente CB ($\theta = 3.0$ vs $\theta = 4.0$)

Confrontando le performance del modello Content-Based al variare della soglia per la costruzione del profilo utente P_u :

Soglia Profilo Utente	MovieLens 100k RMSE	MovieLens 1M RMSE
$\theta = 3.0$ (Rating ≥ 3)	1.2938	1.2847
$\theta = 4.0$ (Rating ≥ 4)	1.2798	1.2721

Risultato: Selezionare esclusivamente i film valutati con voto elevato (≥ 4) consente di costruire profili utente più puliti e caratterizzanti, riducendo l'errore del modello CB in entrambi i dataset.

4.4 Valutazione di Ranking Top-N (Precision@K, NDCG@K)

La valutazione delle raccomandazioni Top-N (soglia di rilevanza per rating ≥ 4.0) rivela un incremento cruciale della qualità di ranking sul dataset MovieLens 1M:

Modello	ML-100k Prec@5	ML-100k NDCG@5	ML-1M Prec@5	ML-1M NDCG@5	ML-1M Prec@10	ML-1M NDCG@10
CF-only ($\alpha = 1.0$)	0.0057	0.0071	0.0169	0.0207	0.0121	0.0164
CB-only ($\alpha = 0.0$)	0.0115	0.0129	0.0170	0.0173	0.0160	0.0181
Hybrid ($\alpha^* = 0.9$)	0.0041	0.0051	0.0235	0.0269	0.0211	0.0252

Analisi del Ranking su MovieLens 1M:

Sul dataset MovieLens 1M, il modello Ibrido ($\alpha = 0.9$) ottiene un netto salto di prestazioni:

- **Precision@5:** sale da 0.0169 (CF puro) a 0.0235 (+39,0% di miglioramento relativo).
- **NDCG@5:** sale da 0.0207 (CF puro) a 0.0269 (+29,9% di miglioramento relativo).

Questo evidenzia come nei cataloghi estesi (3.883 film), la combinazione del segnale collaborativo latente con i profili di genere guidi l'ordinamento dei Top-N in posizioni significativamente più rilevanti.

4.5 Esperimento Cold Start (Item con < 3 valutazioni)

Nello scenario critico di **Cold Start** su film con pochissime valutazioni nel training set:

Modello	ML-100k Cold RMSE	ML-1M Cold RMSE	ML-1M Cold MAE
User Mean Baseline	1.1793	1.2347	0.9842
CF-only ($\alpha = 1.0$)	1.4929	1.4708	1.1807
CB-only ($\alpha = 0.0$)	1.5197	1.5783	1.2653
Hybrid ($\alpha = 0.5$)	1.3881	1.4254	1.1702
Hybrid ($\alpha = 0.9$)	1.4156	1.4278	1.1589




Figura 4: Performance in scenario Cold Start su film con pochissime valutazioni.

Analisi: In presenza di gravi carenze di interazioni per gli item, la fusione bilanciata ($\alpha = 0.5$) consente al sistema di attenuare il degrado del filtro collaborativo riducendo l'RMSE Cold Start rispetto al CF puro (1.4254 vs 1.4708).

4.6 Validazione Statistica

Il test di significatività condotto sulle predizioni di MovieLens 1M ha confermato la validità statistica:

- **Hybrid vs CF-only:** $t = -7.6750$, $p = 0.0015 < 0.05$ (Miglioramento statisticamente significativo).
- **Hybrid vs CB-only:** $t = -445.6688$, $p = 0.0000 < 0.05$ (Miglioramento nettamente significativo).

5. Discussione e Conclusioni

5.1 Risposta alla Domanda Guida del Progetto

"Grazie al volume di 100.000 valutazioni la fattorizzazione di matrice (SVD) riesce a ricostruire con elevata precisione lo spazio latente ($\alpha^* = 1.0$). Questa cosa cambierà passando a 1 Milione di valutazioni?"

Risposta Sperimentale:

Passando da 100.000 a 1.000.209 valutazioni la situazione **cambia significativamente a favore delle prestazioni complessive e del ranking Top-N:**

1. **Accuratezza Predittiva (RMSE):** L'errore del modello cade da 0.9445 a 0.8971 (miglioramento del $-5, 0\%$). L'aumento di 10 volte nel volume dei rating permette all'SVD di affinare i fattori latenti in modo drammatico.
2. **Sinergia Ibrida nei Top-N:** Mentre su ML-100k la scarsa granularità dei generi limitava l'ibridazione nei Top-N, su ML-1M la combinazione $\alpha^* = 0.9$ supera nettamente sia il solo CF che il solo CB, incrementando la Precision@5 del **+39%** e l'NDCG@5 del **+30%**.
3. **Resistenza al Cold Start:** Nei film poco valutati, l'apporto del modulo Content-Based con peso bilanciato ($\alpha = 0.5$) previene i fallimenti catastrofici del CF.

5.2 Sviluppi Futuri

- Valutazione su **MovieLens 25M** (25 milioni di valutazioni) sfruttando le 1.128 dimensioni del Tag Genome per arricchire la profilazione del contenuto.
- Implementazione di modelli di fusione non lineari basati su **Gradient Boosted Decision Trees (XGBoost/LightGBM)** e reti neurali deep & cross.

6. Bibliografia e Sitografia

1. Ricci, F., Rokach, L., & Shapira, B. (2015). *Recommender Systems Handbook*. Springer.
2. Koren, Y., Bell, R., & Volinsky, C. (2009). *Matrix factorization techniques for recommender systems*. Computer, 42(8), 30-37.
3. GroupLens Research — MovieLens 100k & 1M Datasets:
<https://grouplens.org/datasets/movielens/>