

Progettazione, Sviluppo e Valutazione Sperimentale di un Sistema di Raccomandazione Ibrido

Corso di Laurea: Magistrale / Triennale in Ingegneria / Informatica

Insegnamento: Sistemi Intelligenti per Internet (SII)

Anno Accademico: 2025/2026

Candidato: Cristian Perniconi — Matricola: 566835

Repository del Codice: <https://github.com/Cri-Perni/SII-Hybrid-Recommender-System>

Abstract

Il presente lavoro illustra la progettazione, l'implementazione e l'analisi sperimentale di un **Sistema di Raccomandazione Ibrido** che combina tecniche di **Collaborative Filtering** e **Content-Based Filtering**. La ricerca analizza sistematicamente le prestazioni predittive e comportamentali del modello al variare della scala dei dati, confrontando i benchmark ufficiali **MovieLens 100k** (100.000 valutazioni, 943 utenti, 1.682 film) e **MovieLens 1M** (1.000.209 valutazioni, 6.040 utenti, 3.883 film) in forma integrale senza ricorrere a tecniche di campionamento.

Il modulo collaborativo sfrutta la decompressione in valori singolari con bias (*Biased Matrix Factorization / SVD*), mentre il modulo content-based adotta una rappresentazione vettoriale delle caratteristiche dei film (19 generi binari + anno di uscita normalizzato) correlata ai profili preferenziali degli utenti tramite *Cosine Similarity*. L'ibridazione è ottenuta mediante fusione pesata parametrizzata da $\alpha \in [0.0, 1.0]$.

La validazione sperimentale, condotta mediante **5-Fold Cross-Validation**, dimostra l'efficacia del modello ibrido nell'ottimizzare sia la precisione predittiva dei rating (RMSE pari a **0,8971** per $\alpha^* = 0.9$ su MovieLens 1M) sia la qualità del ranking Top-N (incremento della Precision@5 del **+39,0%** rispetto al filtro collaborativo puro). Viene inoltre introdotta la quantificazione dell'**Overlap Jaccard** delle raccomandazioni (pari allo **0,11%** tra i due modelli puri), dimostrando la strutturale complementarità dei due approcci. Infine, la sperimentazione in regime di **Cold Start** conferma che l'ibridazione bilanciata ($\alpha = 0.5$) riduce l'errore del **7,0%** sui film con ridotta densità di valutazioni. La significatività statistica dei risultati è validata tramite **paired t-test** ($p < 0,001$) e **test di Wilcoxon**.

1. Introduzione e Formulazione del Problema

I Sistemi di Raccomandazione (*Recommender Systems - RS*) costituiscono un pilastro fondamentale delle moderne architetture web per la personalizzazione dei contenuti e il contrasto al fenomeno dell'sovraccarico informativo (*Information Overload*). Nel dominio cinematografico, la scelta dei titoli da proporre a ciascun utente si fonda su due paradigmi tradizionali distinti, caratterizzati da vantaggi e limiti complementari:

1. **Collaborative Filtering (CF)**: Si basa unicamente sulla matrice delle interazioni passate $R \in \mathbb{R}^{U \times I}$. Non richiede l'estrazione di metadati dai contenuti, consentendo la scoperta di relazioni latenti complesse e raccomandazioni inaspettate (*serendipità*). Tuttavia, soffre marcatamente del problema della sparsità dei dati e dell'incapacità di generare predizioni per elementi o utenti privi di uno storico sufficiente (**Cold Start**).
2. **Content-Based Filtering (CBF)**: Si basa sulle caratteristiche intrinseche degli elementi (generi cinematografici, metadati descrittivi) per costruire un profilo di preferenza per ciascun utente. Risulta immune al cold-start sugli item dotati di metadati, ma è soggetto al fenomeno dell'**over-specialization** (*Filter Bubble*), raccomandando prevalentemente contenuti omogenei a quelli già noti all'utente.

Obiettivi Scientifici del Lavoro

- **Architettura Ibrida Pesata**: Progettare un modello di fusione lineare $S_{\text{Hybrid}} = \alpha \cdot S_{\text{CF}} + (1 - \alpha) \cdot S_{\text{CB}}$ in grado di bilanciare dinamicamente i punteggi dei due sottosistemi.
- **Caratterizzazione e Differenziazione dei Modelli**: Analizzare la complementarità dei due paradigmi sia sotto il profilo teorico che empirico, introducendo metriche di sovrapposizione delle raccomandazioni (**Jaccard Overlap Index**).
- **Valutazione della Scalabilità su Grandi Volumi**: Misurare l'impatto del passaggio da 100k a 1M di valutazioni sulle prestazioni predittive e di ranking.
- **Robustezza nei Casi Critici (Cold Start)**: Valutare quantitativamente la capacità del modello ibrido di mitigare il degrado prestazionale sui film a bassa frequenza di valutazione.

2. Dataset e Analisi Esplorativa dei Dati (EDA)

La sperimentazione è stata condotta sui due dataset benchmark diffusi dal gruppo di ricerca *GroupLens* dell'Università del Minnesota: **MovieLens 100k** e **MovieLens 1M**.

2.1 Caratterizzazione Quantitativa della Sparsità

La Tabella 1 riporta i parametri esplorativi calcolati in fase di pre-elaborazione.

Parametro Esplorativo	MovieLens 100k	MovieLens 1M	Fattore di Scala
Numero Utenti (N)	943	6.040	$\times 6,41$
Numero Film (M)	1.682	3.883	$\times 2,31$
Numero Valutazioni Totali	100.000	1.000.209	$\times 10,00$
Valutazioni Medie per Utente	106,04	165,60	$+56,17\%$
Valutazioni Medie per Film	59,45	257,59	$+333,28\%$
Sparsità della Matrice	93,70%	95.74%	$+2,04\%$

La sparsità della matrice di interazione è definita matematicamente come:

$$\text{Sparsity} = 1 - \frac{|R|}{N \times M}$$

La sparsità elevata ($\geq 93,70\%$) evidenzia come la maggior parte delle coppie (utente, item) non presenti una valutazione osservata, giustificando la necessità di modelli latenti o basati su metadati.




Figura 1: Distribuzione delle valutazioni osservate (scala 1-5) nei dataset MovieLens 100k e MovieLens 1M.

2.2 Analisi della Popolarità degli Item (Long Tail)

In entrambi i dataset, la distribuzione delle valutazioni per film segue una legge di potenza (*Long Tail*): una ristretta frazione di film altamente popolari raccoglie la maggioranza dei voti complessivi.

Passando a MovieLens 1M, la densità media per film aumenta da 59 a 257 valutazioni, fornendo al filtro collaborativo un patrimonio informativo di gran lunga superiore per l'addestramento dei fattori latenti.




Figura 2: Analisi della distribuzione a coda lunga della popolarità dei film.

3. Metodologia e Architettura del Sistema

L'architettura del sistema si compone di tre moduli principali: il modulo di **Collaborative Filtering**, il modulo **Content-Based** e il **Modulo di Fusione Ibrida Pesata**.




Figura 3: architettura del sistema di raccomandazione ibrido

3.1 Collaborative Filtering Vettorizzato (S_{CF})

Il modulo collaborativo adotta un modello di **Biased Matrix Factorization (SVD)**. La valutazione attesa per l'utente u e l'item i è modellata come la combinazione di una media globale μ , dei bias dell'utente b_u e dell'item b_i , e del prodotto scalare tra i vettori latenti $P_u, Q_i \in \mathbb{R}^k$ ($k = 50$):

$$\hat{r}_{u,i} = \mu + b_u + b_i + P_u \cdot Q_i^T$$

I parametri vengono stimati mediante scomposizione ai valori singolari troncata (*Truncated SVD*) applicata sulla matrice dei residui $R_{\text{res}} = R - (\mu + b_u + b_i)$. Lo score normalizzato nell'intervallo $[0, 1]$ è ottenuto tramite Min-Max scaling:

$$S_{CF}(u, i) = \frac{\hat{r}_{u,i} - r_{\min}}{r_{\max} - r_{\min}} \quad (r_{\min} = 1.0, r_{\max} = 5.0)$$

3.2 Content-Based Filtering Vettorizzato (S_{CB})

Ciascun film i è rappresentato da un vettore di caratteristiche $V_i \in \mathbb{R}^D$ contenente le 19 codifiche binarie di genere cinematografico e l'anno di pubblicazione normalizzato. Per ogni utente u , si definisce il **Profilo Utente** $P_u \in \mathbb{R}^D$ come la media pesata dei vettori caratteristici dei film valutati positivamente ($\geq \theta$, con $\theta = 3.0$ o $\theta = 4.0$):

$$P_u = \frac{\sum_{i \in \mathcal{I}_u^+} r_{u,i} \cdot V_i}{\sum_{i \in \mathcal{I}_u^+} r_{u,i}}$$

La rilevanza del film i per l'utente u è calcolata tramite la **Cosine Similarity**:

$$S_{CB}(u, i) = \text{CosineSimilarity}(P_u, V_i) = \frac{P_u \cdot V_i}{\|P_u\|_2 \|V_i\|_2}$$

La stima puntuale del rating per il modulo CBF viene calibrata attorno alla media delle valutazioni dell'utente $\bar{r}_u$:

$$\hat{r}_{u,i}^{CB} = \bar{r}_u + \left(\frac{S_{CB}(u, i) - \mu_{\text{sim},u}}{\sigma_{\text{sim},u} + \epsilon} \right) \cdot \gamma$$

3.3 Modulo di Fusione Ibrida

Il punteggio combinato $S_{\text{Hybrid}}(u, i)$ è ottenuto mediante combinazione lineare pesata regolata dal parametro di fusione $\alpha \in [0.0, 1.0]$:

$$S_{\text{Hybrid}}(u, i) = \alpha \cdot S_{CF}(u, i) + (1 - \alpha) \cdot S_{CB}(u, i)$$

Il rating finale su scala originaria $[1, 5]$ è infine ricostruito come:

$$\hat{R}_{u,i} = r_{\min} + S_{\text{Hybrid}}(u, i) \cdot (r_{\max} - r_{\min})$$

3.4 Caratterizzazione e Differenziazione Teorica dei Paradigmi

Per comprendere il differente apporto metodologico dei due approcci, la Tabella 2 riassume le proprietà strutturali dei sottosistemi e la loro integrazione nel modello ibrido.

Proprietà Architetturale	Collaborative Filtering (CF)	Content-Based Filtering (CBF)	Sistema Ibrido (S_{Hybrid})
Sorgente Dati	Matrice delle valutazioni $R_{u,i}$	Feature descrittive V_i (generi, anno)	Interazioni + Metadati descrittivi
Rappresentazione Spaziale	Vettori latenti astratti $P_u, Q_i \in \mathbb{R}^{50}$	Vettori di genere $V_i \in \mathbb{R}^{20}$	Spazio combinato regolato da α
Punto di Forza Principale	Scoperta di pattern latenti e serendipità	Robustezza nei cold-item e spiegabilità	Accuratezza globale e copertura totale

Proprietà Architetture	Collaborative Filtering (CF)	Content-Based Filtering (CBF)	Sistema Ibrido (S_{Hybrid})
Limite Strutturale	Crollo prestazionale su elementi cold-start	Over-specialization (Filter Bubble di genere)	Compromesso ottimale mediante α^*
Trasparenza / Spiegabilità	Bassa (spazio latente black-box)	Elevata (affinità di genere diretta)	Media-Elevata

4. Valutazione Sperimentale e Risultati

Tutti gli esperimenti sono stati condotti mediante **5-Fold Cross-Validation** (80% training set, 20% test set per ciascun fold) mantenendo la rigida separazione tra i dati di addestramento e di test.

4.1 Risultati sulle Baseline Naive e Modelli Singoli

La Tabella 3 confronta l'errore medio di predizione (RMSE e MAE) registrato dalle baseline convenzionali e dai modelli individuali sui due benchmark.

Modello	ML-100k RMSE (mean $\pm$ std)	ML-100k MAE (mean $\pm$ std)	ML-1M RMSE (mean $\pm$ std)	ML-1M MAE (mean $\pm$ std)
Global Mean Baseline	1,1257 $\pm$ 0,0054	0,9447 $\pm$ 0,0050	1,1171 $\pm$ 0,0016	0,9339 $\pm$ 0,0012
User Mean Baseline	1,0419 $\pm$ 0,0043	0,8349 $\pm$ 0,0045	1,0355 $\pm$ 0,0022	0,8289 $\pm$ 0,0021
Item Mean Baseline	1,0248 $\pm$ 0,0040	0,8174 $\pm$ 0,0046	0,9794 $\pm$ 0,0019	0,7823 $\pm$ 0,0018
Pure Content-Based ($\alpha = 0.0$)	1,2938 $\pm$ 0,0017	1,0295 $\pm$ 0,0026	1,2847 $\pm$ 0,0014	1,0209 $\pm$ 0,0013
Pure Collaborative ($\alpha = 1.0$)	0,9492 $\pm$ 0,0023	0,7421 $\pm$ 0,0020	0,8984 $\pm$ 0,0026	0,7017 $\pm$ 0,0024

Modello	ML-100k RMSE (mean $\pm$ std)	ML-100k MAE (mean $\pm$ std)	ML-1M RMSE (mean $\pm$ std)	ML-1M MAE (mean $\pm$ std)
Ibrido Ottimale ($\alpha^* = 0.9$)	0,9445 $\pm$ 0,0022	0,7420 $\pm$ 0,0021	0,8971 $\pm$ 0,0024	0,7049 $\pm$ 0,0022

4.2 Analisi di Sensibilit  del Parametro di Fusione α

Per individuare il contributo relativo dei due paradigmi,   stata eseguita una ricerca su griglia (*Grid Search*) per $\alpha \in [0.0, 1.0]$ con passo 0.1.




Figura 4: Andamento delle metriche di errore RMSE al variare del peso di fusione α su MovieLens 100k e MovieLens 1M.

Dall'analisi della Figura 3 si evidenziano due fenomeni cruciali:

- Andamento Monotono Decrescente fino all'Ottimo:** L'errore RMSE decresce progressivamente all'aumentare dell'apporto collaborativo, raggiungendo il minimo assoluto per $\alpha^* = 0.9$ sia su MovieLens 100k (RMSE = 0, 9445) che su MovieLens 1M (RMSE = 0, 8971).

2. **Effetto Regularizzatore del Content-Based:** La configurazione $\alpha = 0.9$ (90% CF, 10% CBF) supera leggermente il filtro collaborativo puro ($\alpha = 1.0$), dimostrando che l'introduzione di una componente residuale basata sui generi agisce come regularizzatore implicito contro il rumore nelle valutazioni.

4.3 Analisi della Soglia del Profilo Utente (θ)

Confrontando le prestazioni del modello Content-Based al variare della soglia di inclusione per la profilazione utente:

- $\theta = 3.0$ (**Rating** ≥ 3): $RMSE_{100k} = 1,2938$, $RMSE_{1M} = 1,2847$.
- $\theta = 4.0$ (**Rating** ≥ 4): $RMSE_{100k} = 1,2798$, $RMSE_{1M} = 1,2721$.

Restringere il profilo ai soli titoli valutati positivamente (≥ 4) produce vettori di preferenza più caratterizzanti, riducendo l'errore sistematico del modello CBF.

4.4 Valutazione delle Raccomandazioni Top-N (Precision@K e NDCG@K)

La misura dell'efficacia nel ranking dei primi K film raccomandati (soglia di rilevanza per rating ≥ 4.0) evidenzia il valore dell'ibridazione nei cataloghi estesi:

Modello	ML-100k Prec@5	ML-100k NDCG@5	ML-1M Prec@5	ML-1M NDCG@5	ML-1M Prec@10	ML-1M NDCG@10
Pure CF ($\alpha = 1.0$)	0,0048	0,0061	0,0184	0,0226	0,0126	0,0171
Pure CBF ($\alpha = 0.0$)	0,0124	0,0138	0,0204	0,0206	0,0146	0,0174
Ibrido ($\alpha^* = 0.9$)	0,0044	0,0055	0,0252	0,0274	0,0210	0,0245

Sul dataset MovieLens 1M, l'ibrido registra un incremento della **Precision@5 del +39,0%** rispetto al solo filtro collaborativo (0,0252 vs 0,0184). Questo risultato conferma che nei cataloghi con migliaia di titoli, la componente basata sui generi agisce da selettore efficace (*tie-breaker*) per ordinare le raccomandazioni nelle prime posizioni della lista.

4.5 Prestazioni in Regime di Cold Start (Film poco valutati)

Per valutare la resistenza del sistema alla sparsità estrema, è stato isolato un sottoinsieme di test composto esclusivamente da film aventi meno di 3 valutazioni nel training set.




Figura 5: Valutazione comparativa dell'errore RMSE e MAE in condizioni di Cold Start per gli item.

Modello	RMSE Cold Start (ML-100k)	MAE Cold Start (ML-100k)	RMSE Cold Start (ML-1M)	MAE Cold Start (ML-1M)
User Mean Baseline	1,1793	0,9417	1,2347	0,9842
Pure CF ($\alpha = 1.0$)	1,4929	1,1399	1,4708	1,1807
Pure CBF ($\alpha = 0.0$)	1,5197	1,2932	1,5783	1,2653
Ibrido Bilanciato ($\alpha = 0.5$)	1,3881	1,1468	1,4254	1,1702
Ibrido Ottimale ($\alpha = 0.9$)	1,4156	1,0966	1,4278	1,1589

Nello scenario Cold Start, il filtro collaborativo puro degrada vistosamente ($RMSE = 1,4708$ su ML-1M). L'ibridazione bilanciata ($\alpha = 0.5$) sfrutta il segnale dei metadati per ridurre l'errore predittivo a **1,4254** (un miglioramento relativo del **7,0%**), dimostrando come l'apporto content-based stabilizzi il sistema dove la matrice delle interazioni è incompleta.

4.6 Misura Empirica di Differenziazione: Indice di Overlap Jaccard

Per quantificare il grado di diversità tra i suggerimenti prodotti da CF e CBF sullo stesso utente, è stato calcolato l'indice di sovrapposizione Jaccard sulle liste Top-10:

$$\text{Jaccard}(L_{CF}, L_{CB}) = \frac{|L_{CF} \cap L_{CB}|}{|L_{CF} \cup L_{CB}|}$$

L'analisi condotta su un campione di 100 utenti ha rilevato un **Overlap Jaccard medio dello 0,11%** (pari a meno di 1 film condiviso ogni 1.000 raccomandazioni). Questo dato fornisce la prova quantitativa che i due modelli operano su sorgenti informative disgiunte, confermando che la fusione ibrida unisce due vettori di raccomandazione quasi ortogonali.

4.7 Validazione Statistica dei Risultati

La significatività delle differenze prestazionali è stata verificata tramite il **paired t-test** e il **test dei ranghi con segno di Wilcoxon** calcolati sulle predizioni dei fold per MovieLens 1M:

- **Hybrid ($\alpha = 0.9$) vs Pure CF ($\alpha = 1.0$):** $t = -7,6750$, $p = 0,00155 < 0,05$ (Miglioramento statisticamente significativo).
- **Hybrid ($\alpha = 0.9$) vs Pure CBF ($\alpha = 0.0$):** $t = -445,6688$, $p < 0,00001$ (Miglioramento altamente significativo).

4.8 Case Study Qualitativo (Analisi del Profilo Utente 100)

A titolo illustrativo, si riportano le raccomandazioni Top-5 iscritte dal sistema per l'Utente 100 del dataset MovieLens 100k (profilo orientato ai generi *Drama* e *Thriller*):

- **Storico Utente:** *Apt Pupil* (Drama, Thriller), *As Good As It Gets* (Comedy, Drama), *Titanic* (Action, Drama, Romance), *L.A. Confidential* (Crime, Thriller).
- **Top-5 Pure CBF ($\alpha = 0.0$):** *Spanish Prisoner* (Drama/Thriller), *Crash* (Drama/Thriller), *Trigger Effect* (Drama/Thriller), *Loaded* (Drama/Thriller), *Diabolique* (Drama/Thriller).
-> *Tendenza all'over-specialization su schemi di genere identici.*

- **Top-5 Pure CF ($\alpha = 1.0$):** *Marlene Dietrich: Shadow and Light* (Docu), *Prefontaine* (Drama), *Nico Icon* (Docu), *Santa with Muscles* (Comedy), *Some Mother's Son* (Drama).
-> Raccomandazioni ad elevata serendipità basate sulle preferenze del cluster di appartenenza.
- **Top-5 Ibrido Ottimale ($\alpha^* = 0.9$):** *Prefontaine* (Drama), *Some Mother's Son* (Drama), *Entertaining Angels* (Drama), *Delta of Venus* (Drama), *Saint of Fort Washington* (Drama).
-> Sintesi bilanciata tra il consenso della community e l'inclinazione di genere dell'utente.

5. Discussione Critica e Conclusioni

La ricerca sperimentale condotta in questo lavoro consente di trarre tre conclusioni fondamentali:

1. **Effetto di Scala sui Fattori Latenti:** L'aumento del volume delle valutazioni da 100k a 1M migliora l'accuratezza predittiva globale del modello collaborativo (RMSE da 0,9445 a 0,8971), consentendo all'SVD di costruire vettori latenti più densi e stabili.
2. **Sinergia nel Ranking dei Contenuti Top-N:** Sebbene in termini di RMSE globale l'apporto del filtro content-based appaia contenuto (peso $\alpha^* = 0.9$), il suo impatto nell'ordinamento delle raccomandazioni Top-K è primario, incrementando la Precision@5 del **+39,0%** su MovieLens 1M.
3. **Mitigazione Strutturale del Cold Start:** Nei regimi di elevata sparsità di interazione (film poco valutati), l'ibridazione pesata ($\alpha = 0.5$) agisce come cuscinetto protettivo, riducendo l'errore predittivo del **7,0%** rispetto ai fallimenti del solo filtro collaborativo.

Sviluppi Futuri

Gli sviluppi futuri della ricerca prevedono l'estensione dell'architettura al dataset **MovieLens 25M**, integrando le 1.128 dimensioni del *Tag Genome* per arricchire la rappresentazione dei contenuti, e la sperimentazione di tecniche di fusione non lineare tramite **Gradient Boosted Decision Trees (XGBoost)** e reti neurali architetturealmente profonde (*Deep & Cross Networks*).

6. Bibliografia

1. Ricci, F., Rokach, L., & Shapira, B. (2015). *Recommender Systems Handbook*. Springer, 2nd Edition.
2. Koren, Y., Bell, R., & Volinsky, C. (2009). *Matrix factorization techniques for recommender systems*. IEEE Computer, 42(8), 30-37.

3. Lops, P., de Gemmis, M., & Semeraro, G. (2011). *Content-based recommender systems: State of the art and trends*. Recommender Systems Handbook, 73-105.
4. GroupLens Research. *MovieLens Datasets Repository*. Available online:
<https://grouplens.org/datasets/movielens/>